

Sinyal işleme ses sinyallerinin yapısını incelemektedir.

Ses diki olupturan en lise
15°C'lik hava içerisinde sesin hızı 340 m/s olmaktadır.

Sesin oluşumu
Edels → insan sesinin oluşumunda başlıca dört olayın yer aldığını belirtmiştir. Sırayla

- 4) Artikülasyon
Her bir bileşik titreşim hareketidir. Benzer ve genlikleri farklı.



Sarıyedeki bu titreşim sayısı Hz (hertz)'le ölçülmektedir.

Frekans ve tınıdan sonra sesin ilavesi özelliği siddetidir.

Bir sesin enerjisi ise onun watt cinsinden ölçülen gücüyle etkide bulunmaktadır. Dolayısıyla enerji 1cm^2 'ye gelen (1)

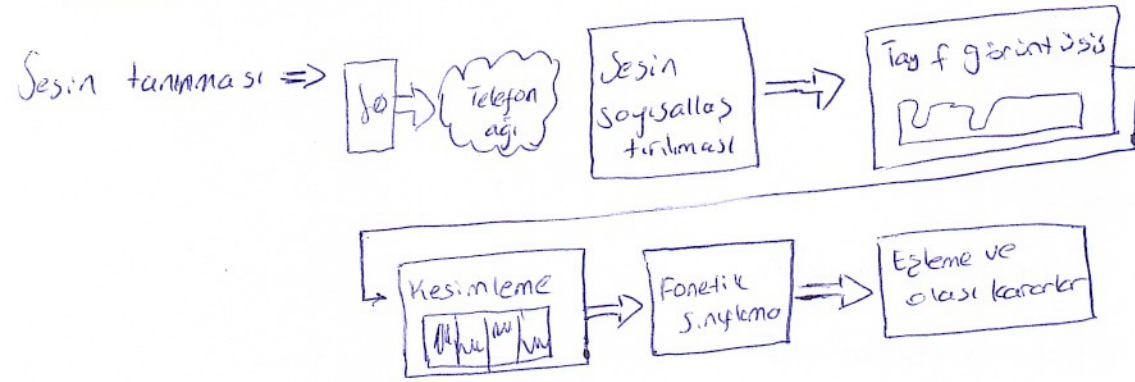
Aksan \Rightarrow Temel tonun frekansının değişmesine denir.

Sert sesler yüksek, yumuşak sesler ise düşük yoğunluktadır.

* Konuşmanın dinamik aralığı 35-45 dB'dir.

* Ünlü seslerin sürekliliği ortalama 0.15s

* İnsüzlerin ise 0.08s'dir.



Konuşmacı Tanıma \Rightarrow Gelen ses sinyaliye göre konuşanın kimliği tanıma işlemidir.

Anahtar sözcük yakalama \Rightarrow Bu sistemlerde kalıp kelimeler aranmaktadır.

Ses bilgisi mikrafon gibi dönüştürücüler yardımıyla elektriksel işarete çevrilebilir. Sonra analog bir bilgi olan ses, sayılar tekniklerinin daha kolay gerçekleştirilebilmesi ve hızlı gerçekleştirilmesi sağlanmaktadır.

Mono \Rightarrow tek kanal yardımıyla gerçekleştirilen kayıtlar mono, iki kanal kullananlar ise stereo olarak adlandırılır.

Hızlı Fourier Dönüşümü (Fast Fourier Transform FFT)
mikrafona gelen ses gürültüler içermektedir. Beyaz gürültülere daha çok gürültü. Beyaz gürültünün frekansı ana bileşene göre çok yüksektir, ve iki komşu değerin salınım yapan ekşene olan uzaklıkları farklıdır. Sıfır olmaktadır.


$$x(t) = C_0 + \sum_{k=0}^{\infty} (a_k \cos(k\omega_1 t) + b_k \sin(k\omega_1 t))$$

↓
ayrık işaret
(Zaman)

C_0 , a_k ve b_k ise Fourier katsayılarını ifade etmektedir

$$\omega_1 = 2\pi f_0 \quad f_0 \rightarrow \text{temel frekans}$$

- Bayes Kuralı -



$$A = (A \cap D_1) \cup (A \cap D_2) \cup \dots \cup (A \cap D_n)$$

A olayının gerçekleşmesi olasılığı

$$P(A) = P(A \cap D_1) + P(A \cap D_2) + \dots + P(A \cap D_n)$$

$$P(A \cap D) = P(A|D)P(D) \text{ olduğunda,}$$

$$P(A) = P(A|D_1)P(D_1) + P(A|D_2)P(D_2) + \dots + P(A|D_n)P(D_n) = \sum_{i=1}^n P(A|D_i)P(D_i)$$

⇒ Bu sonuca toplam olasılık teoremi denir.

$$P(A \cap D) = P(A|D)P(D) \text{ olduğundan her hanki bir k değeri için.}$$

$$P(D_k|A) = P(D_k \cap A) / P(A)$$

$$P(D_k|A) = P(D_k)P(A|D_k) / P(A)$$

P(A) için toplam olasılık teoreminden faydalanarak;

$$P(D_k|A) = \frac{P(D_k)P(A|D_k)}{\sum_{i=1}^n P(D_i)P(A|D_i)} \Rightarrow \text{Bayes teoremi}$$

Y ⇒ yarın yağmurun olması
B ⇒ Bugünkü hava

$$\left. \begin{array}{l} Y \Rightarrow \text{yarın yağmurun olması} \\ B \Rightarrow \text{Bugünkü hava} \end{array} \right\} \text{Bayes kuralı } P(Y|B) = P(B|Y)P(Y) / P(B|Y)P(Y) + P(B|\neg Y)P(\neg Y)$$

Eğer P(Y|B) biliniyorsa Bayes kuralı kullanılır.

Bayes teoreminin, tü kombinasyonların hesaplanmasına dayalı yöntemden farklı değerler bir biri ile korelasyon oluşturduğundan tüm durumları denemeden karar verme imkanının olmasıdır.

Veriler temelinde bilgisayarın kendini "geliştirerek" yeni bilgiler kazanması bilgisayarlı öğrenme (machine learning) denilir.

Satlı Markov Modeli (HMM) Baum ve meslektaşları tarafından 1970'li yılların

başlarında geliştirilmiştir.

Yöntemin temelini (t-1) anındaki durum bilindiğinden t anındaki durumun değerilendirilmesi mantığı oluşturmaktadır.

⇒ Eğitim aşamasında ise kelimelerin modeli oluşturam M ilişkisi bulunur

$$P(t) = A * P(t-1)$$

$$M = [N, P(1), A, B]$$

N ⇒ Durum sayısı

P(1) ⇒ Başlangıç durumu

A ⇒ Geçiş Matrisi

B ⇒ İstenilen durum

Think DSP

! Nump - SciPy

Extensively \rightarrow yoğun olarak

Assume \Rightarrow varsaymak

Digital signal processing in Python

* Think Python

* Mark Lutz's Learning Python

* Numpy for basic numerical computation

* SciPy for scientific computation

* Matplotlib for visualization

Sounds and signals

A signal represents a quantity that varies in time.

Sound is variation in air pressure. A sound signal represents variations in air pressure over time.

\rightarrow The frequency of a signal is the number of cycles per second, which is the inverse of the period.


The units of frequency are cycles per second, or Hertz ^(hesaltıklan) abbreviated 'Hz'.

The shape of periodic signal is called the waveform.

Discrete Fourier Transform (DFT) (Ayrık Fourier dönüşümü)

Bir sinyali alır ve spektrumunu üretir.

Fast Fourier transform or FFT which is an efficient way to compute the DFT



A wave represent a signal evaluated at a sequence of points in time. Each point in time is called a frame.

`wave = mix.make_wave(duration=0.5, start=0, framerate=11025)`

Duration is the length of the wave in seconds.

Framerate is the (integer) number of frames per second, which is also the number of samples per second.


- Signal objects -

Sinusoid is a child class of Signal, with this definition

```
class Sinusoid(Signal):
```

```
    def __init__(self, freq=440, amp=1.0, offset=0, func=np.sin):
        Signal.__init__(self)
        self.freq = freq
        self.amp = amp
        self.offset = offset
        self.func = func
```

The parameters of `--init--` are:

 **freq** \Rightarrow frequency in cycles per second or Hz.

amp \Rightarrow Amplitude. The units of amplitude are arbitrary, usually chosen so 1.0 corresponds to the maximum input from a microphone or maximum output to speaker.

offset: indicates where in its period the signal ~~at a particular~~ ~~position~~ starts.

func \Rightarrow A python function used to evaluate the signal at a particular point in time. it is usually either `np.sin` or `np.cos` yielding a sine or cosine signal.

Frame rate is the number of frames (samples) per second.

```
def make_wave(self, duration=1, start=0, framerate=11025):
```

```
    n = round(duration * framerate)
```

n number of samples

```
    ts = start + np.arange(n)/framerate
```

ts is an Numpy array of sample times.

```
    ys = self.evaluate(ts)
```

```
    return wave(ys, ts, framerate=framerate)
```

```
def evaluate(self, ts):
```

```
    phases = PI2 * self.freq * ts + self.offset
```

```
    ys = self.amp * self.func(phases)
```

```
    return ys
```

self.freq \rightarrow $\text{sanige basını dangu chisiden frekanstin.}$
frequency in cycles per second

self.func \Rightarrow is `np.sin` or `np.cos`, the result is a value between -1 +1.


PI2 \rightarrow is a constant that stores 2π

self.offset \Rightarrow is the phase when $t=0$

- Spectrogram -

To recover the relationship between frequency and time, we can break the chirp into segments and plot the spectrum of each segment.

The result is called a short-time Fourier transform (STFT)



Spectrogram shows clearly that frequency increases linearly over time.

- Noise -

In English "noise" means an unwanted or unpleasant sound.

If two signals interfere with each other, each signal would consider the other to be noise.

- Uncorrelated Noise -

The simple way to understand noise is to generate it, and the simplest kind to generate is uncorrelated uniform noise (UU noise)

Uniform means the signal contains random values from a uniform distribution.

Every value in the range is equally likely.

! Frequencies is called white noise by analogy with light, because an equal mixture of light at all visible frequencies is white.

- Pink Noise -

$$P = K / f^\beta$$

$\beta = 0$, power is constant at all frequencies, so the result is white noise.

when $\beta = 2$ the result is red noise.

when β is between 0 and 2 the result is between white and red noise, so it's called pink noise.

There are several ways to generate pink noise. The simplest is to generate white noise and then apply a low-pass filter with the desired exponent.

Like noise as "uncorrelated" which means that each value is independent of the others. (11)

- Correlation as dot Product -

In signal processing, we are often working with unbiased signals, where the mean is 0, and normalized signals, where the standard deviation is 1,

ρ simplifies to;

$$\rho = \frac{1}{N} \sum_i x_i y_i$$

- Using Numpy -

`corr2 = np.correlate(segment.y_s, segment.y_s, mode='same')`

- Discrete cosine Transform -

which is used in MP3 and related formats for compressing music.

DCT is similar in many ways to the Discrete Fourier Transform (DFT) which we have been using for spectral analysis.

$$M = \cos(2\pi t \otimes f)$$

```
def analyze(y_s, f_s, t_s):  
    args = np.outer(t_s, f_s)  
    M = np.cos(PI2 * args)  
    amps = np.linalg.solve(M, y_s)  
    return amps
```

- Orthogonal matrices -

One way to solve linear systems is by ^{Levinson}inverting matrices. The inverse of a matrix M is written M^{-1} , and it has the property that $M^{-1}M = I$. I is the identity matrix, which has the value 1 on all diagonal elements and 0 everywhere else.

$$M^{-1}y = \underbrace{M^{-1}Ma}_{\rightarrow I} \rightarrow I$$

$$M^{-1}y = Ia$$

If we multiply I by any vector a , the result is a , so

$$M^{-1}y = a$$

$$M^T = M^{-1}$$

$$M^T M = I$$